

รายงานการทดสอบการอ่านเอกสารภาษาไทย

บทที่หนึ่ง ข้อมูลทั่วไป

ประเทศไทยตั้งอยู่ในภูมิภาคเอเชียตะวันออกเฉียงใต้ มีพื้นที่ประมาณห้าแสนหนึ่งหมื่นสามพันตารางกิโลเมตร และมีประชากรราวเจ็ดสิบล้านคน ภาษาไทยเป็นภาษาราชการของประเทศ เขียนด้วยอักษรไทยซึ่งไม่มีการเว้นวรรคระหว่างคำ การเว้นวรรคจะใช้เพื่อแบ่งประโยคหรือวลีเท่านั้น ดังนั้นโปรแกรมที่ประมวลผลข้อความภาษาไทยจึงต้องไม่เพิ่มช่องว่างเมื่อรวมบรรทัดเข้าด้วยกัน

กรุงเทพมหานครเป็นเมืองหลวงและเป็นศูนย์กลางทางเศรษฐกิจ การคมนาคม และการศึกษาของประเทศ มีประชากรอาศัยอยู่หนาแน่นมากที่สุด นอกจากนี้ยังมีเมืองสำคัญอื่นเช่น เชียงใหม่ ขอนแก่น และภูเก็ต ซึ่งแต่ละแห่งมีลักษณะทางวัฒนธรรมที่แตกต่างกันออกไป

บทที่สอง ข้อความผสมสองภาษา

ระบบ OCR ต้องรองรับภาษาไทย และ English ในเอกสารเดียวกัน โดยเก็บช่องว่างระหว่างคำภาษาอังกฤษไว้ตามเดิม เช่น the quick brown fox jumps over the lazy dog แต่ต้องไม่แทรกช่องว่างเข้าไปในคำภาษาไทย

ตัวเลขและหน่วยเช่น 1,250 บาท หรือ 25 องศาเซลเซียส ต้องคงรูปแบบเดิมไว้ทุกประการ